AIT3003 – KHAI PHÁ VÀ PHÂN TÍCH DỮ LIỆU
(2627I_AIT3003_1)

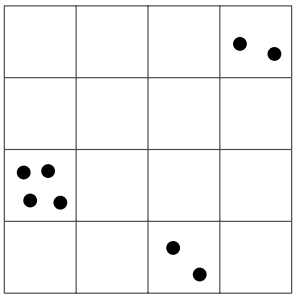
TUẦN 4 – PROBLEM SET 4

Họ và tên: Đinh Mai Hữu Toàn
Mã sinh viên: 23021904

Bài 1 Cho tập dữ liệu gồm 8 điểm phân bố trong lưới 4×4 như hình. Tính entropy H theo phương pháp *cell-based entropy*.

Bài giải

Chia không gian thành 16 ô (cell) bằng nhau. Đếm số điểm trong từng ô; các ô không chứa điểm có xác suất bằng 0.



Có ba ô khác rỗng với số điểm tương ứng là 4, 2 và 2. Vì tổng số điểm $N = 8$, phân bố xác suất trên các ô khác rỗng là:

$$p_1 = \frac{4}{8} = \frac{1}{2}, \qquad p_2 = \frac{2}{8} = \frac{1}{4}, \qquad p_3 = \frac{2}{8} = \frac{1}{4}.$$

Theo công thức Shannon với logarithm cơ số 2 (quy ước $0 \log_2 0 = 0$):

$$\begin{aligned} H &= -\sum_{i=1}^{16} p_i \log_2 p_i \\ &= -\left(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{4}\log_2 \frac{1}{4} + \frac{1}{4}\log_2 \frac{1}{4} \right) \\ &= -\left(-\frac{1}{2} - \frac{1}{2} - \frac{1}{2} \right) = \boxed{1{,}5 \text{ bits}}. \end{aligned}$$

Kết luận: Cell-based entropy của phân bố 8 điểm là $H = 1{,}5$ bits. Nếu dùng entropy chuẩn hóa theo 16 ô thì $H / \log_2(16) = 1{,}5/4 = 0{,}375$; đề bài chỉ yêu cầu H nên đáp số chính là $1{,}5$ bits.

Bài 2 Cho tám điểm $A_1(2,10), A_2(2,5), A_3(8,4), B_1(5,8), B_2(7,5),\ B_3(6,4), C_1(1,2), C_2(4,9)$. Áp dụng k-means với $k=3$, khoảng cách Euclidean và các tâm khởi tạo A_1, B_1, C_1. Xác định (a) ba tâm sau vòng đầu và (b) ba cụm cuối cùng.

Bài giải

Ký hiệu ba cụm là K_1, K_2, K_3. Tâm ban đầu theo đúng thứ tự của đề là:

$$\mu_1^{(0)} = (2,10), \quad \mu_2^{(0)} = (5,8), \quad \mu_3^{(0)} = (1,2).$$

Sử dụng bình phương khoảng cách Euclidean để so sánh (không làm thay đổi tâm gần nhất):

$$d^2\big((x,y),(a,b)\big) = (x-a)^2 + (y-b)^2.$$

Vòng lặp 1 – phân điểm theo các tâm ban đầu. Ví dụ với $A_2 = (2,5)$:

$$\begin{aligned} d^2(A_2, \mu_1^{(0)}) &= (2-2)^2 + (5-10)^2 = 25, \\ d^2(A_2, \mu_2^{(0)}) &= (2-5)^2 + (5-8)^2 = 18, \\ d^2(A_2, \mu_3^{(0)}) &= (2-1)^2 + (5-2)^2 = 10. \end{aligned}$$

Vì 10 nhỏ nhất nên A_2 được gán vào cụm K_3. Làm tương tự cho toàn bộ tám điểm:

Điểm	$d^2(\cdot, \mu_1^{(0)})$	$d^2(\cdot, \mu_2^{(0)})$	$d^2(\cdot, \mu_3^{(0)})$	**Cụm**
A_1	0	13	65	K_1
A_2	25	18	10	K_3
A_3	72	25	53	K_2
B_1	13	0	52	K_2
B_2	50	13	45	K_2
B_3	52	17	29	K_2
C_1	65	52	0	K_3
C_2	5	2	58	K_2

Do đó, sau bước gán điểm ở vòng đầu:

$$\begin{aligned} K_1^{(1)} &= \{A_1\}, \\ K_2^{(1)} &= \{A_3, B_1, B_2, B_3, C_2\}, \\ K_3^{(1)} &= \{A_2, C_1\}. \end{aligned}$$

Tâm mới bằng trung bình cộng tọa độ tất cả điểm trong mỗi cụm:

$$\begin{aligned} \mu_1^{(1)} &= (2,10), \\ \mu_2^{(1)} &= \left(\frac{8+5+7+6+4}{5}, \frac{4+8+5+4+9}{5}\right) = (6,6), \\ \mu_3^{(1)} &= \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = (1{,}5;\ 3{,}5). \end{aligned}$$

Đáp án (a): Sau vòng lặp thứ nhất, ba tâm lần lượt là $\boxed{(2,10),\ (6,6),\ (1{,}5;\ 3{,}5)}$.

Các vòng tiếp theo – lặp lại bước gán điểm và cập nhật tâm.

Vòng 2. Với các tâm $\mu^{(1)}$, điểm $C_2 = (4, 9)$ chuyển từ K_2 sang K_1 vì:

$$d^2(C_2, \mu_1^{(1)}) = 5 < d^2(C_2, \mu_2^{(1)}) = 13 < d^2(C_2, \mu_3^{(1)}) = 36{,}5.$$

Như vậy $K_1^{(2)} = \{A_1, C_2\}$, $K_2^{(2)} = \{A_3, B_1, B_2, B_3\}$ và $K_3^{(2)} = \{A_2, C_1\}$. Các tâm cập nhật:

$$\mu_1^{(2)} = (3;\, 9{,}5), \quad \mu_2^{(2)} = (6{,}5;\, 5{,}25), \quad \mu_3^{(2)} = (1{,}5;\, 3{,}5).$$

Vòng 3. Với $\mu^{(2)}$, điểm $B_1 = (5, 8)$ chuyển từ K_2 sang K_1 vì:

$$d^2(B_1, \mu_1^{(2)}) = 6{,}25 < d^2(B_1, \mu_2^{(2)}) = 9{,}8125 < d^2(B_1, \mu_3^{(2)}) = 32{,}5.$$

Các tâm cập nhật sau khi gán lại toàn bộ điểm là:

$$\begin{aligned}
\mu_1^{(3)} &= \left(\frac{2+5+4}{3}, \frac{10+8+9}{3}\right) = \left(\frac{11}{3}, 9\right), \\
\mu_2^{(3)} &= \left(\frac{8+7+6}{3}, \frac{4+5+4}{3}\right) = \left(7, \frac{13}{3}\right), \\
\mu_3^{(3)} &= \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = \left(\frac{3}{2}, \frac{7}{2}\right).
\end{aligned}$$

Vòng 4. Kiểm tra lại khoảng cách tới ba tâm $\mu^{(3)}$:

Điểm	$d^2(\cdot, \mu_1^{(3)})$	$d^2(\cdot, \mu_2^{(3)})$	$d^2(\cdot, \mu_3^{(3)})$	**Cụm**
A_1	3,778	57,111	42,5	K_1
A_2	18,778	25,444	2,5	K_3
A_3	43,778	1,111	42,5	K_2
B_1	2,778	17,444	32,5	K_1
B_2	27,111	0,444	32,5	K_2
B_3	30,444	1,111	20,5	K_2
C_1	56,111	41,444	2,5	K_3
C_2	0,111	30,778	36,5	K_1

Các giá trị trong bảng được làm tròn đến ba chữ số thập phân. Việc gán điểm không thay đổi, do đó thuật toán đã hội tụ.

Đáp án (b): Ba cụm cuối cùng và các tâm tương ứng là:

$$\boxed{\begin{aligned}
K_1 &= \{A_1, B_1, C_2\}, \quad \mu_1 = \left(\frac{11}{3}, 9\right), \\
K_2 &= \{A_3, B_2, B_3\}, \quad \mu_2 = \left(7, \frac{13}{3}\right), \\
K_3 &= \{A_2, C_1\}, \qquad \mu_3 = \left(\frac{3}{2}, \frac{7}{2}\right).
\end{aligned}}$$

Bài 3 Cho ma trận khoảng cách của sáu đối tượng A, B, C, D, E, F. Vẽ dendrogram cho (a) liên kết đơn và (b) liên kết hoàn chỉnh.

	A	B	C	D	E	F
A	0	0,12	0,51	0,84	0,28	0,34
B	0,12	0	0,25	0,16	0,77	0,61
C	0,51	0,25	0	0,14	0,70	0,93
D	0,84	0,16	0,14	0	0,45	0,20
E	0,28	0,77	0,70	0,45	0	0,67
F	0,34	0,61	0,93	0,20	0,67	0

Bài giải

a) Phân cụm phân cấp theo liên kết đơn (single linkage).

Khoảng cách giữa hai cụm U, V là khoảng cách *nhỏ nhất* giữa một cặp điểm thuộc hai cụm:

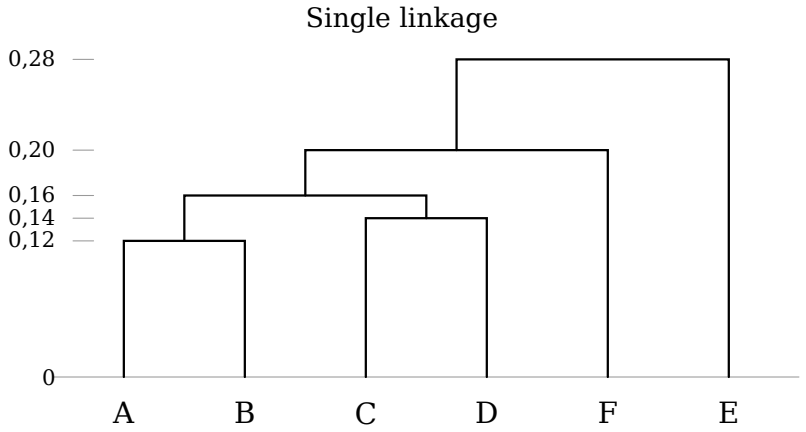
$$d_{\min}(U, V) = \min_{u \in U,\, v \in V} d(u, v).$$

Lần lượt ghép hai cụm có khoảng cách nhỏ nhất:

Bước	**Hai cụm được ghép**	**Cụm mới**	**Độ cao**
1	A và B	$\{A, B\}$	0,12
2	C và D	$\{C, D\}$	0,14
3	$\{A, B\}$ và $\{C, D\}$	$\{A, B, C, D\}$	0,16
4	$\{A, B, C, D\}$ và F	$\{A, B, C, D, F\}$	0,20
5	$\{A, B, C, D, F\}$ và E	$\{A, B, C, D, E, F\}$	0,28

Chẳng hạn, ở bước 3:

$$d_{\min}(\{A, B\}, \{C, D\}) = \min\{0{,}51;\ 0{,}84;\ 0{,}25;\ 0{,}16\} = 0{,}16.$$



Chú ý: Thứ tự lá A, B, C, D, F, E được sắp để biểu đồ dễ đọc; không làm thay đổi kết quả phân cụm.

b) Phân cụm phân cấp theo liên kết hoàn chỉnh (complete linkage).

Khoảng cách giữa hai cụm U, V là khoảng cách *lớn nhất* giữa một cặp điểm thuộc hai cụm:

$$d_{\max}(U,V) = \max_{u\in U,\, v\in V} d(u,v).$$

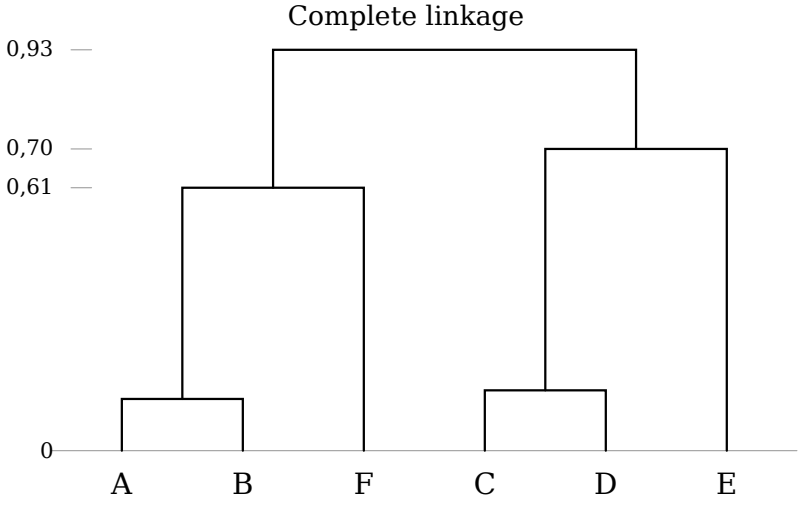
Hai phép ghép đầu tiên vẫn là A với B tại $0{,}12$, và C với D tại $0{,}14$. Sau đó, với bốn cụm $\{A,B\}, \{C,D\}, E, F$, ta có:

$$\begin{aligned}
d_{\max}(\{A,B\},F) &= \max\{0{,}34;\ 0{,}61\} = 0{,}61,\\
d_{\max}(\{C,D\},E) &= \max\{0{,}70;\ 0{,}45\} = 0{,}70,\\
d_{\max}(E,F) &= 0{,}67,\\
d_{\max}(\{A,B\},E) &= \max\{0{,}28;\ 0{,}77\} = 0{,}77,\\
d_{\max}(\{A,B\},\{C,D\}) &= 0{,}84,\\
d_{\max}(\{C,D\},F) &= \max\{0{,}93;\ 0{,}20\} = 0{,}93.
\end{aligned}$$

Giá trị nhỏ nhất trong các khoảng cách còn lại là $0{,}61$, nên ghép $\{A,B\}$ với F; tiếp theo ghép $\{C,D\}$ với E ở mức $0{,}70$. Cuối cùng:

$$d_{\max}(\{A,B,F\},\{C,D,E\}) = 0{,}93 \quad \text{(do } d(F,C) = 0{,}93\text{)}.$$

Bước	Hai cụm được ghép	Cụm mới	Độ cao
1	A và B	$\{A,B\}$	$0{,}12$
2	C và D	$\{C,D\}$	$0{,}14$
3	$\{A,B\}$ và F	$\{A,B,F\}$	$0{,}61$
4	$\{C,D\}$ và E	$\{C,D,E\}$	$0{,}70$
5	$\{A,B,F\}$ và $\{C,D,E\}$	$\{A,B,C,D,E,F\}$	$0{,}93$



Chú ý: Thứ tự lá được sắp thành A, B, F, C, D, E để biểu đồ không cắt chéo; độ cao mỗi nút chính là khoảng cách tại bước ghép.

Kết luận: Liên kết đơn ghép hết các điểm ở mức $0{,}28$; liên kết hoàn chỉnh ghép hết các điểm ở mức $0{,}93$. Vì lấy khoảng cách lớn nhất giữa hai cụm, complete linkage tạo những cụm chặt chẽ hơn trước bước ghép cuối.