AIT3003 – KHAI PHÁ VÀ PHÂN TÍCH DỮ LIỆU
(2627I_AIT3003_1)

TUẦN 2 – PROBLEM SET 2

Họ và tên: Đinh Mai Hữu Toàn
Mã sinh viên: 23021904

Bài 1 Trong dữ liệu thực tế, các bộ dữ liệu (tuples) bị thiếu giá trị ở một số thuộc tính là hiện tượng thường gặp. Hãy mô tả các phương pháp khác nhau để xử lý vấn đề này.

Bài giải

Dữ liệu thiếu có thể được xử lý theo nhiều cách. Việc lựa chọn phương pháp phụ thuộc vào tỷ lệ dữ liệu thiếu, kiểu thuộc tính và mục đích phân tích.

1. Loại bỏ bộ dữ liệu có giá trị thiếu (ignore/delete the tuple). Cách này đơn giản và phù hợp khi số bộ bị thiếu rất nhỏ so với toàn bộ dữ liệu. Tuy nhiên, nếu loại bỏ quá nhiều bộ thì có thể làm mất thông tin và gây sai lệch mẫu.
2. Điền thủ công (manual filling). Người xử lý tự xác định giá trị bị thiếu dựa vào hồ sơ hoặc nguồn dữ liệu gốc. Cách này có thể chính xác nhưng tốn thời gian và khó áp dụng cho tập dữ liệu lớn.
3. Thay bằng một hằng số toàn cục. Có thể dùng một giá trị như “Unknown”, “N/A” hoặc một mã đặc biệt. Cách này giữ lại bộ dữ liệu nhưng có thể tạo ra một nhóm giá trị nhân tạo nếu thuật toán xem hằng số đó như một giá trị bình thường.
4. Thay bằng giá trị trung bình hoặc trung vị của thuộc tính. Với thuộc tính số, có thể dùng mean hoặc median. Median thường bền vững hơn khi dữ liệu có ngoại lệ. Với thuộc tính phân loại, có thể dùng giá trị xuất hiện nhiều nhất (mode).
5. Thay bằng giá trị trung bình/mốt theo cùng lớp. Nếu dữ liệu có nhãn lớp, ta tính mean, median hoặc mode trong chính lớp chứa bộ dữ liệu bị thiếu. Cách này thường hợp lý hơn so với dùng một giá trị chung cho toàn bộ tập.
6. Ước lượng giá trị có khả năng nhất. Có thể dự đoán giá trị thiếu bằng hồi quy, cây quyết định, k-nearest neighbors, Bayesian hoặc các mô hình học máy khác. Phương pháp này tận dụng mối quan hệ giữa các thuộc tính nhưng phức tạp hơn và cần kiểm soát sai số dự đoán.

Nhận xét: Không có một phương pháp duy nhất phù hợp cho mọi trường hợp. Trước khi điền dữ liệu, cần kiểm tra nguyên nhân và cơ chế thiếu dữ liệu để tránh tạo ra sai lệch cho kết quả phân tích.

Bài 2 Cho dữ liệu tuổi được sắp xếp tăng dần:

$$13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70.$$

(a) Dùng phương pháp làm trơn bằng trung bình của các bin (smoothing by bin means) với độ sâu bin bằng 3. Trình bày các bước và nhận xét ảnh hưởng của kỹ thuật này.

(b) Có thể xác định các giá trị ngoại lệ (outliers) trong dữ liệu như thế nào?

(c) Còn những phương pháp nào khác để làm trơn dữ liệu?

Bài giải

a Làm trơn bằng trung bình của bin với bin depth = 3

Có $n = 27$ giá trị. Với độ sâu bin bằng 3, ta chia dữ liệu thành:

$$\frac{27}{3} = 9 \text{ bin},$$

mỗi bin chứa đúng 3 giá trị liên tiếp.

Bin	Giá trị ban đầu	Trung bình bin	Giá trị sau làm trơn
1	13, 15, 16	$44/3 \approx 14.67$	14.67, 14.67, 14.67
2	16, 19, 20	$55/3 \approx 18.33$	18.33, 18.33, 18.33
3	20, 21, 22	$63/3 = 21$	21, 21, 21
4	22, 25, 25	$72/3 = 24$	24, 24, 24
5	25, 25, 30	$80/3 \approx 26.67$	26.67, 26.67, 26.67
6	33, 33, 35	$101/3 \approx 33.67$	33.67, 33.67, 33.67
7	35, 35, 35	$105/3 = 35$	35, 35, 35
8	36, 40, 45	$121/3 \approx 40.33$	40.33, 40.33, 40.33
9	46, 52, 70	$168/3 = 56$	56, 56, 56

Dữ liệu sau khi làm trơn là:

$$\{14.67, 14.67, 14.67,\ 18.33, 18.33, 18.33,\ 21, 21, 21,\\ 24, 24, 24,\ 26.67, 26.67, 26.67,\ 33.67, 33.67, 33.67,\\ 35, 35, 35,\ 40.33, 40.33, 40.33,\ 56, 56, 56\}.$$

Nhận xét: kỹ thuật này làm giảm dao động cục bộ và nhiễu trong từng nhóm. Tuy nhiên, các giá trị ban đầu bị thay bằng một giá trị đại diện nên thông tin chi tiết bị mất. Hiệu ứng thể hiện rõ ở bin cuối: $46, 52, 70$ đều bị đưa về 56; do đó giá trị lớn 70 bị kéo xuống đáng kể.

Smoothing by bin means tạo 9 bin, mỗi bin gồm 3 phần tử.

b Xác định outlier

Một cách thông dụng là sử dụng quy tắc IQR của boxplot. Với dữ liệu trên:

$$Q_1 = 20, \qquad Q_3 = 35.$$

Do đó:

$$IQR = Q_3 - Q_1 = 35 - 20 = 15.$$

Ngưỡng dưới và ngưỡng trên là:

$$Q_1 - 1.5IQR = 20 - 1.5(15) = -2.5,$$

$$Q_3 + 1.5IQR = 35 + 1.5(15) = 57.5.$$

Mọi giá trị nhỏ hơn -2.5 hoặc lớn hơn 57.5 được xem là ngoại lệ theo quy tắc này. Trong tập dữ liệu chỉ có:

$$70 > 57.5.$$

$$\boxed{70 \text{ là outlier theo quy tắc } 1.5 \times IQR.}$$

Ngoài IQR, có thể dùng z-score, phân tích khoảng cách, clustering hoặc mô hình phát hiện bất thường tùy loại dữ liệu.

c Các phương pháp làm trơn khác

Ngoài bin means, có thể sử dụng:

- Smoothing by bin medians: thay các giá trị trong mỗi bin bằng trung vị của bin.
- Smoothing by bin boundaries: thay mỗi giá trị bằng giá trị biên gần nó nhất trong bin.
- Regression: dùng hàm hồi quy để mô hình hóa xu hướng rồi làm trơn các điểm quanh đường/hàm hồi quy.
- Clustering: gom các điểm tương tự thành cụm; các điểm xa cụm có thể được xem là nhiễu hoặc ngoại lệ và xử lý riêng.

Bài 3 Thảo luận các vấn đề cần xem xét trong quá trình tích hợp dữ liệu (data integration).

Bài giải

Data integration là quá trình kết hợp dữ liệu từ nhiều nguồn thành một kho dữ liệu thống nhất. Các vấn đề quan trọng gồm:

1. Schema integration và entity identification. Cần xác định các trường ở những nguồn khác nhau có cùng biểu diễn một thực thể hay không. Ví dụ, `student_id` ở hệ thống A có thể tương ứng với `id_sv` ở hệ thống B.
2. Dư thừa dữ liệu (redundancy). Một thuộc tính có thể được lưu lặp lại hoặc suy ra từ thuộc tính khác. Dư thừa làm tăng kích thước dữ liệu và có thể gây mâu thuẫn nếu các bản sao không đồng nhất. Phân tích tương quan hoặc phụ thuộc hàm có thể giúp phát hiện vấn đề này.
3. Trùng lặp bản ghi. Cùng một đối tượng có thể xuất hiện nhiều lần với cách viết tên, mã hoặc địa chỉ hơi khác nhau. Cần record linkage/entity matching để phát hiện và hợp nhất.
4. Xung đột giá trị dữ liệu. Hai nguồn có thể dùng đơn vị, thang đo, mã hóa hoặc quy ước khác nhau, ví dụ kg và lb; ngày theo DD/MM/YYYY và MM/DD/YYYY; giới tính dùng M/F hoặc 0/1.
5. Không nhất quán về kiểu dữ liệu và miền giá trị. Cần thống nhất kiểu số, chuỗi, ngày tháng, phạm vi hợp lệ, precision và cách biểu diễn giá trị thiếu.
6. Tính toàn vẹn và tính nhất quán. Sau khi tích hợp cần kiểm tra khóa chính, khóa ngoại, ràng buộc miền, các luật nghiệp vụ và quan hệ giữa các bảng.
7. Nguồn gốc và chất lượng dữ liệu. Nên lưu metadata/provenance để biết dữ liệu đến từ đâu, thời điểm cập nhật nào và nguồn nào được ưu tiên khi có xung đột.

Kết luận: mục tiêu của data integration không chỉ là ghép dữ liệu lại, mà còn phải bảo đảm cùng ngữ nghĩa, hạn chế dư thừa, xử lý xung đột và duy trì độ tin cậy của dữ liệu sau tích hợp.

Bài 4 Hãy cho biết miền giá trị của các phương pháp chuẩn hóa sau:

(a) Min-max normalization.

(b) Z-score normalization.

(c) Z-score normalization sử dụng mean absolute deviation thay cho standard deviation.

(d) Normalization by decimal scaling.

Bài giải

Phương pháp	Miền giá trị sau chuẩn hóa
Min-max normalization	Nằm trong khoảng đích $[new_min, new_max]$; nếu chuẩn hóa chuẩn về $[0, 1]$ thì kết quả thuộc $[0, 1]$.
Z-score normalization	Không bị chặn cố định: $(-\infty, +\infty)$.
Z-score dùng mean absolute deviation	Không bị chặn cố định: $(-\infty, +\infty)$.
Decimal scaling	Chọn j sao cho $\max(\lvert v' \rvert) < 1$, vì vậy kết quả nằm trong $(-1, 1)$.

Công thức tương ứng:

$$v' = \frac{v - \min(A)}{\max(A) - \min(A)}(new_max - new_min) + new_min,$$

$$z = \frac{v - \mu}{\sigma}, \qquad z_{MAD} = \frac{v - \mu}{MAD}, \qquad v' = \frac{v}{10^j}.$$

Bài 5 Sử dụng dữ liệu tuổi ở Bài 2 để trả lời:

(a) Dùng min-max normalization để biến đổi giá trị 35 về khoảng $[0.0, 1.0]$.

(b) Dùng z-score normalization để biến đổi giá trị 35, biết độ lệch chuẩn của tuổi là 12.94 năm.

(c) Dùng decimal scaling để biến đổi giá trị 35.

(d) Nhận xét phương pháp nào phù hợp hơn với dữ liệu này và giải thích.

Bài giải

Từ tập dữ liệu:

$$\min(A) = 13, \qquad \max(A) = 70, \qquad \bar{x} = \frac{809}{27} \approx 29.96.$$

a Min-max normalization về $[0, 1]$

Công thức:

$$v' = \frac{v - \min(A)}{\max(A) - \min(A)}.$$

Với $v = 35$:

$$v' = \frac{35 - 13}{70 - 13} = \frac{22}{57} \approx 0.38596.$$

Giá trị 35 sau min-max normalization ≈ 0.386.

b Z-score normalization

Công thức:

$$z = \frac{v - \bar{x}}{s}.$$

Với $v = 35$, $\bar{x} \approx 29.96$ và $s = 12.94$:

$$z = \frac{35 - 29.96}{12.94} = \frac{5.04}{12.94} \approx 0.389.$$

Giá trị 35 sau z-score normalization ≈ 0.389.

c Normalization by decimal scaling

Công thức:

$$v' = \frac{v}{10^j},$$

trong đó j là số nguyên nhỏ nhất sao cho giá trị tuyệt đối lớn nhất sau chuẩn hóa nhỏ hơn 1.

Vì giá trị lớn nhất của tập là 70 nên cần $j = 2$:

$$\frac{70}{10^2} = 0.70 < 1.$$

Do đó:

$$v' = \frac{35}{100} = 0.35.$$

Giá trị 35 sau decimal scaling $= 0.35$.

d Lựa chọn phương pháp

Nếu mục tiêu là đưa dữ liệu vào một khoảng cố định, chẳng hạn $[0, 1]$ cho một thuật toán yêu cầu đầu vào bị chặn, min-max normalization là lựa chọn trực tiếp nhất. Tuy nhiên, dữ liệu này có giá trị 70 là một ngoại lệ theo quy tắc IQR, nên min-max bị ảnh hưởng khá rõ bởi cực trị này.

Trong ba phương pháp được yêu cầu, nếu mục tiêu là chuẩn hóa để so sánh và mô hình hóa thống kê, z-score normalization thường phù hợp hơn vì biểu diễn mỗi giá trị theo số độ lệch chuẩn so với trung bình và phản ánh độ phân tán của dữ liệu. Dù vậy, z-score vẫn có thể bị ảnh hưởng bởi outlier vì cả mean và standard deviation đều nhạy với giá trị cực trị.

Decimal scaling rất đơn giản nhưng chỉ thay đổi bậc độ lớn; nó không phản ánh vị trí của giá trị so với trung tâm và độ phân tán của tập dữ liệu.

Ưu tiên z-score cho so sánh/mô hình hóa; dùng min-max nếu bắt buộc khoảng $[0, 1]$.

Bài 6 Đề xuất một thuật toán, bằng mã giả hoặc ngôn ngữ lập trình, để tự động tạo concept hierarchy cho dữ liệu định danh (nominal data) dựa trên số lượng giá trị phân biệt (distinct values) của các thuộc tính trong schema.

Bài giải

Ý tưởng chính: thuộc tính có nhiều giá trị phân biệt hơn thường nằm ở mức khái niệm chi tiết hơn (lower level), còn thuộc tính có ít giá trị phân biệt hơn thường nằm ở mức tổng quát hơn (higher level).

Ví dụ, nếu ta có các thuộc tính:

$$\text{Street} \to \text{City} \to \text{State} \to \text{Country},$$

thì thông thường số lượng giá trị phân biệt giảm dần từ Street đến Country.

Mã giả:

```
Algorithm GenerateConceptHierarchy(D, NominalAttributes)
Input:
    D: dataset
    NominalAttributes = {A1, A2, ..., Ak}
Output:
    H: concept hierarchy from detailed level to general level

1. Create empty list L
2. For each attribute Ai in NominalAttributes:
       ni = number of distinct non-null values of Ai in D
       append (Ai, ni) to L
3. Sort L by ni in descending order
4. Create hierarchy H using the sorted attributes:
       L[1].attribute -> L[2].attribute -> ... -> L[k].attribute
5. If two attributes have the same number of distinct values:
       place them at the same conceptual level, or
       use schema/functional-dependency information to break the tie
6. Return H
```

Giải thích: Giả sử ta đếm được:

Thuộc tính	Số giá trị phân biệt
Street	10,000
City	500
State/Province	50
Country	10

Khi sắp xếp giảm dần theo số distinct values, ta thu được:

$$\boxed{\text{Street} \rightarrow \text{City} \rightarrow \text{State/Province} \rightarrow \text{Country}}$$

trong đó Street là mức chi tiết nhất và Country là mức tổng quát nhất.

Lưu ý: số distinct values chỉ là một heuristic để tự động xây dựng hierarchy. Nếu có metadata, quan hệ khóa hoặc functional dependency thì nên sử dụng chúng để kiểm tra lại thứ tự, vì không phải mọi cặp thuộc tính có số lượng distinct khác nhau đều thực sự có quan hệ khái quát hóa.

Hết