AIT3003 – KHAI PHÁ VÀ PHÂN TÍCH DỮ LIỆU
(2627I_AIT3003_1)

TUẦN 3 – PROBLEM SET 3

Họ và tên: Đinh Mai Hữu Toàn
Mã sinh viên: 23021904

Bài 1 Cho hai đối tượng được biểu diễn bằng các bộ số $A = (22, 1, 42, 10)$ và $B = (20, 0, 36, 8)$:

(a) Tính khoảng cách Euclidean giữa hai đối tượng.
(b) Tính khoảng cách Manhattan giữa hai đối tượng.
(c) Tính khoảng cách Minkowski với $q = 3$.

Bài giải

Hiệu tuyệt đối của từng cặp tọa độ là:

$$(|22-20|, |1-0|, |42-36|, |10-8|) = (2, 1, 6, 2).$$

a) Khoảng cách Euclidean (L_2):

$$d_E(A,B) = \sqrt{(22-20)^2 + (1-0)^2 + (42-36)^2 + (10-8)^2}$$

$$= \sqrt{4+1+36+4} = \sqrt{45} = 3\sqrt{5} \approx 6{,}7082.$$

b) Khoảng cách Manhattan (L_1):

$$d_M(A,B) = |22-20| + |1-0| + |42-36| + |10-8|$$

$$= 2+1+6+2 = 11.$$

c) Khoảng cách Minkowski ($q = 3$):

$$d_3(A,B) = \left(\sum_{i=1}^{4} |A_i - B_i|^3\right)^{1/3} = \sqrt[3]{2^3 + 1^3 + 6^3 + 2^3}$$

$$= \sqrt[3]{8+1+216+8} = \sqrt[3]{233} \approx 6{,}1534.$$

Vậy ba khoảng cách lần lượt là $\sqrt{45} \approx 6{,}7082$; 11; và $\sqrt[3]{233} \approx 6{,}1534$.

Bài 2 Cho hai câu sau và tính độ tương tự Jaccard bằng cách coi mỗi câu là một tập từ:

(a) "ông già đi nhanh quá".
(b) "thời_gian trôi đi nhanh quá".

Bài giải

Tách từ theo khoảng trắng; chuỗi "thời_gian" được xem là một từ như trong đề bài. Khi đó:

$$A = \{\text{ông, già, đi, nhanh, quá}\}, \qquad |A| = 5,$$
$$B = \{\text{thời_gian, trôi, đi, nhanh, quá}\}, \qquad |B| = 5.$$

Các từ chung của hai câu là "đi", "nhanh", "quá", do đó:

$$A \cap B = \{\text{đi, nhanh, quá}\}, \qquad |A \cap B| = 3.$$

Tập hợp có tổng cộng 7 từ phân biệt: $|A \cup B| = 5 + 5 - 3 = 7$. Độ tương tự Jaccard là:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{3}{7} \approx 0{,}4286 \quad (42{,}86\%).$$

Nhận xét: Hai câu có ba từ chung trong bảy từ phân biệt, nên độ tương tự Jaccard xấp xỉ $0{,}429$.

Bài 3 Biểu diễn hai câu sau bằng vector tần suất từ và tính độ tương tự cosine:

(a) "The sly fox jumped over the lazy dog."
(b) "The dog jumped at the intruder."

Bài giải

Trước tiên, chuyển tất cả từ sang chữ thường và bỏ dấu chấm câu; vẫn giữ các từ như "the". Tập từ vựng chung, theo thứ tự cố định, là:

$$V = (\text{the, sly, fox, jumped, over, lazy, dog, at, intruder}).$$

Tập từ vựng gồm 9 từ phân biệt, nên mỗi vector có 9 chiều. Bảng tần suất:

Từ	the	sly	fox	jumped	over	lazy	dog	at	intruder
Câu (a)	2	1	1	1	1	1	1	0	0
Câu (b)	2	0	0	1	0	0	1	1	1

Suy ra các vector tần suất theo thứ tự từ đã chọn:

$$\vec{x} = (2,1,1,1,1,1,1,0,0), \qquad \vec{y} = (2,0,0,1,0,0,1,1,1).$$

Tích vô hướng của hai vector:

$$\vec{x} \cdot \vec{y} = 2 \cdot 2 + 1 \cdot 1 + 1 \cdot 1 = 6.$$

Độ dài của từng vector:

$$\|\vec{x}\| = \sqrt{2^2 + 1^2 + 1^2 + 1^2 + 1^2 + 1^2 + 1^2} = \sqrt{10},$$
$$\|\vec{y}\| = \sqrt{2^2 + 1^2 + 1^2 + 1^2 + 1^2} = \sqrt{8}.$$

Vì vậy:

$$\text{cosine}(\vec{x},\vec{y}) = \frac{\vec{x} \cdot \vec{y}}{\|\vec{x}\|\|\vec{y}\|} = \frac{6}{\sqrt{10}\sqrt{8}} = \frac{3}{2\sqrt{5}} \approx 0{,}6708.$$

Nhận xét: Hai câu có độ tương tự cosine khoảng $67{,}08\%$ khi biểu diễn bằng tần suất từ và giữ tất cả từ (kể cả "the").

Bài 4 Lập bảng tính khoảng cách soạn thảo Levenshtein cho hai chuỗi “học sinh” và “hojc xih”, sử dụng ba phép toán xóa, chèn và thay thế một ký tự. Lưu ý: ký tự “ọ” được tính là một ký tự.

Bài giải

Đặt $s =$ “học sinh” và $t =$ “hojc xih”. Mỗi chuỗi có 8 ký tự, kể cả dấu cách; “ọ” là một ký tự. Ký hiệu $D[i, j]$ là số phép sửa ít nhất để chuyển i ký tự đầu của s thành j ký tự đầu của t.

Khởi tạo: $D[i, 0] = i$, $D[0, j] = j$. Với $i, j \geq 1$:

$$D[i,j] = \min \begin{cases} D[i-1,j] + 1 & \text{(xóa một ký tự)}, \\ D[i,j-1] + 1 & \text{(chèn một ký tự)}, \\ D[i-1,j-1] + c & \text{(giữ nguyên hoặc thay thế)}, \end{cases}$$

trong đó $c = 0$ nếu $s_i = t_j$ và $c = 1$ nếu $s_i \neq t_j$.

Bảng quy hoạch động (ký hiệu $\varnothing$ là chuỗi rỗng; dấu $\sqcup$ là khoảng trắng):

	$\varnothing$	h	o	j	c	$\sqcup$	x	i	h
$\varnothing$	0	1	2	3	4	5	6	7	8
h	1	0	1	2	3	4	5	6	7
ọ	2	1	1	2	3	4	5	6	7
c	3	2	2	2	2	3	4	5	6
$\sqcup$	4	3	3	3	3	2	3	4	5
s	5	4	4	4	4	3	3	4	5
i	6	5	5	5	5	4	4	3	4
n	7	6	6	6	6	5	5	4	4
h	8	7	7	7	7	6	6	5	4

Vì ô cuối cùng của bảng bằng $D[8, 8] = 4$, khoảng cách Levenshtein là 4.

Một cách biến đổi đạt đúng 4 phép sửa là:

1. Chèn “o” ngay sau “h”: “học sinh” $\rightarrow$ “hoọc sinh”.
2. Thay “ọ” bằng “j”: “hoọc sinh” $\rightarrow$ “hojc sinh”.
3. Thay “s” bằng “x”: “hojc sinh” $\rightarrow$ “hojc xinh”.
4. Xóa “n”: “hojc xinh” $\rightarrow$ “hojc xih”.

Số phép sửa của dãy thao tác trên bằng giá trị nhỏ nhất $D[8, 8]$, nên kết quả là chính xác.