AIT3003 – KHAI PHÁ VÀ PHÂN TÍCH DỮ LIỆU (2627I_AIT3003_1)

TUẦN 1 – PROBLEM SET 1

Họ và tên: Đinh Mai Hữu Toàn
Mã sinh viên: 23021904

Bài 1

Giả sử dữ liệu dùng để phân tích bao gồm thuộc tính *tuổi*. Các giá trị tuổi của các bộ dữ liệu được sắp xếp theo thứ tự tăng dần như sau:

$$\{13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70\}.$$

a. Giá trị trung bình của dữ liệu là bao nhiêu? Trung vị là bao nhiêu?

b. Mốt (Mode) của dữ liệu là gì? Nhận xét về tính đa mốt của dữ liệu (ví dụ: hai mốt, ba mốt, v.v.).

c. Khoảng giữa (midrange) của dữ liệu là bao nhiêu?

d. Có thể xác định gần đúng tứ phân vị thứ nhất (Q_1) và tứ phân vị thứ ba (Q_3) của dữ liệu hay không?

e. Hãy đưa ra *tóm tắt năm số* (five-number summary) của dữ liệu.

f. Vẽ biểu đồ hộp (boxplot) của dữ liệu.

g. Phương sai và độ lệch chuẩn của dữ liệu là bao nhiêu?

Bài giải

Số lượng phần tử của tập dữ liệu là:

$$n = 27$$

a **Giá trị trung bình và trung vị của dữ liệu**
Giá trị trung bình được tính theo công thức:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Tổng các giá trị trong tập dữ liệu là:

$$\sum_{i=1}^{27} x_i = 809$$

Thay vào công thức:

$$\bar{x} = \frac{809}{27} \approx 29.96.$$

Vì có 27 giá trị nên trung vị là giá trị nằm ở vị trí:

$$\frac{n+1}{2} = \frac{27+1}{2} = 14.$$

Giá trị trung vị nằm ở vị trí thứ 14 trong dãy, tức 25. Vậy nên ta có:

$$\boxed{\text{Trung bình} \approx 29.96, \text{Trung vị} = 25}$$

b **Mốt (Mode) của dữ liệu**
Mốt là giá trị xuất hiện với tần suất lớn nhất trong tập, trong dữ liệu độ tuổi, ta thấy:

$$25 \text{ xuất hiện 4 lần}, \quad 35 \text{ xuất hiện 4 lần}$$

Các giá trị còn lại xuất hiện ít hơn 4 lần. Do đó tập dữ liệu có 2 mốt:

$$\boxed{\text{Mode} = 25,\ 35}$$

c **Khoảng giữa (midrange)**
Khoảng giữa được tính bằng trung bình cộng của giá trị nhỏ nhất và giá trị lớn nhất, từ tập dữ liệu về độ tuổi ta có:

$$\text{Min} = 13, \qquad \text{Max} = 70$$

ta có:

$$\text{Midrange} = \frac{13+70}{2} = \frac{83}{2} = 41.5.$$

Vậy:

$$\boxed{\text{Midrange} = 41.5}$$

d **Tứ phân vị thứ nhất và thứ ba**
Trung vị của toàn bộ dữ liệu là 25. Loại giá trị trung vị ra khỏi tập dữ liệu, ta có hai nửa. Nửa dưới gồm:

$$13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25.$$

Có 13 giá trị, nên trung vị của nửa dưới nằm ở vị trí:

$$\frac{13+1}{2} = 7$$

Giá trị thứ 7 là 20. Do đó:

$$Q_1 = 20$$

Nửa trên gồm:

$$30, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70.$$

Có 13 giá trị, nên trung vị của nửa trên cũng nằm ở vị trí:

$$\frac{13+1}{2} = 7$$

Giá trị thứ 7 là 35. Do đó:

$$Q_3 = 35$$

Vậy:

$$\boxed{Q_1 = 20, \quad Q_3 = 35}$$

e **Tóm tắt năm số**
Tóm tắt 5 số gồm:

$$\text{Nhỏ nhất}, \quad Q_1, \quad \text{Trung vị}, \quad Q_3, \quad \text{Lớn nhất}.$$

Từ các kết quả trên, ta có:

Đại lượng	Giá trị
Minium	13
Q_1	20
Trung vị	25
Q_3	35
Lớn nhất	70

f **Vẽ biểu đổ hộp (Boxplot)**
Đầu tiên, ta tính khoảng tứ phân vị (IQR):

$$IQR = Q_3 - Q_1 = 35 - 20 = 15.$$

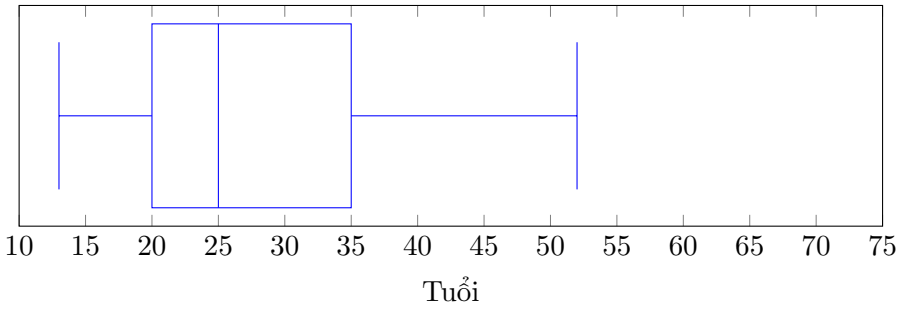
Ngưỡng dưới và ngưỡng trên để xác định ngoại lệ lần lượt là:

$$Q_1 - 1.5IQR = 20 - 1.5(15) = -2.5.$$

Và

$$Q_3 + 1.5IQR = 35 + 1.5(15) = 57.5.$$

Do đó, mọi giá trị lớn hơn 57.5 đều xem là ngoại lệ. Biểu đồ hộp của tập dữ liệu độ tuổi được biểu diễn như sau:



g **Phương sai và độ lệch chuẩn**
Giá trị trung bình đã tính được là:

$$\bar{x} \approx 29.96.$$

Ta có công thức tính phương sai:

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Áp dụng công thức vào tập dữ liệu, ta có:

$$\sigma^2 = \frac{1}{27}\sum_{i=1}^{27}(x_i - 29.96)^2 \approx 194.554.$$

Do đó độ lệch chuẩn là:

$$\sigma = \sqrt{\sigma^2} = \sqrt{194.554} \approx 13.94.$$

Vậy:

$$\boxed{\text{Phương sai} \approx 194.554, \quad \text{Độ lệch chuẩn} \approx 13.94}$$

Tóm tắt đáp án Bài 1

Trung bình	≈ 29.96
Trung vị	$= 25$
Mode	$= 25,\ 35$
Khoảng giữa	$= 41.5$
Q_1	$= 20$
Q_3	$= 35$
Tóm tắt 5 số	$= (13, 20, 25, 35, 70)$
Phương sai	≈ 194.554
Độ lệch chuẩn	≈ 13.94

Bài 2

Giả sử một bệnh viện đã kiểm tra dữ liệu về *tuổi* và *% mỡ cơ thể* của 18 người trưởng thành được lựa chọn ngẫu nhiên, với kết quả như sau:

Tuổi	23	23	27	27	39	41	47	49	50
% mỡ	9.5	26.5	7.8	17.8	31.4	25.9	27.4	27.2	31.2
Tuổi	52	54	54	56	57	58	58	60	61
% mỡ	34.6	42.5	28.8	33.4	30.2	34.1	32.9	41.2	35.7

a. Tính giá trị trung bình, trung vị, phương sai và độ lệch chuẩn của *tuổi* và *% mỡ*.

b. Vẽ biểu đồ hộp (boxplot) cho *tuổi* và *% mỡ*.

c. Vẽ biểu đồ phân tán (scatter plot) cho hai biến này.

d. Tính hệ số tương quan Pearson và Spearman giữa hai thuộc tính.

Bài giải

a. **Tính giá trị trung bình, trung vị, phương sai và độ lệch chuẩn**

Đối với biến tuổi

Giá trị trung bình:

$$\bar{x} = \frac{\sum_{i=1}^{18} x_i}{18} = \frac{836}{18} \approx 46.4.$$

Trung vị: Vì $n = 18$ là số chẵn nên trung vị là trung bình cộng của hai giá trị thứ 9 và thứ 10:

$$x_9 = 50, \quad x_{10} = 52.$$

Do đó:

$$Median = \frac{50 + 52}{2} = 51.$$

Phương sai mẫu:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Thay $n = 18$ và $\bar{x} \approx 46.4$:

$$s^2_{\text{tuổi}} = \frac{1}{17}\sum_{i=1}^{18}(x_i - 46.4)^2 \approx 157.67.$$

Độ lệch chuẩn:

$$s_{\text{tuổi}} = \sqrt{s^2_{\text{tuổi}}} = \sqrt{157.67} \approx 12.56.$$

Đối với biến % mỡ cơ thể

Dầu tiên, ta sắp xếp dữ liệu theo thứ tự tăng dần:

$$7.8,\ 9.5,\ 17.8,\ 25.9,\ 26.5,\ 27.2,\ 27.4,\ 28.8,\ 30.2,$$
$$31.2,\ 31.4,\ 32.9,\ 33.4,\ 34.1,\ 34.6,\ 35.7,\ 41.2,\ 42.5.$$

Giá trị trung bình:

$$\bar{y} = \frac{\sum_{i=1}^{18} y_i}{18} = \frac{518.1}{18} \approx 28.78.$$

Trung vị: Vì $n = 18$ là số chẵn nên trung vị là trung bình cộng của hai giá trị thứ 9 và thứ 10:

$$y_9 = 30.2, \quad y_{10} = 31.2.$$

Do đó:

$$Median = \frac{30.2 + 31.2}{2} = 30.7.$$

Phương sai mẫu:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Thay $n = 18$ và $\bar{x} \approx 28.78$:

$$s^2_{\%\ \text{mỡ}} = \frac{1}{17}\sum_{i=1}^{18}(x_i - 28.78)^2 \approx 84.55.$$

Độ lệch chuẩn:

$$s_{\%\ \text{mỡ}} = \sqrt{s^2_{\%\ \text{mỡ}}} = \sqrt{84.55} \approx 9.2.$$

Vậy, ta có tổng quát đáp án ý a như sau:

Biến	Trung bình	Trung vị	Phương sai	Độ lệch chuẩn
Tuổi	46.40	51.00	157.67	12.56
% mỡ	28.78	30.70	84.55	9.20

b. **Vẽ biểu đồ hộp (Boxplot)**

Tính thông số của biến tuổi

Đầu tiên, ta tính tứ phân vị thứ nhất, tứ phân vị thứ ba và khoảng tứ phân vị.
Ta tiến hành chia dữ liệu thành hai nửa, mỗi nửa gồm 9 giá trị. Nửa dưới:

$$23, 23, 27, 27, 39, 41, 47, 49, 50.$$

Có giá trị trung tâm là:

$$Q_1 = 39$$

Nửa trên:

$$52, 54, 54, 56, 57, 58, 58, 60, 61.$$

Có giá trị trung tâm là:

$$Q_3 = 57$$

Vậy khoảng tứ phân vị, tứ phân vị thứ nhất và thứ ba lần lượt là:

$$IQR = Q_3 - Q_1 = 57 - 39 = 18.$$

$$Q_1 - 1.5IQR = 39 - 1.5(18) = 12.$$

$$Q_3 + 1.5IQR = 57 + 1.5(18) = 84.$$

Vậy, ta có tóm tắt 5 số của biến tuổi lần lượt là: $\boxed{23,\ 39,\ 51,\ 57,\ 61}$

Tính thông số của biến % mỡ

Ta tiến hành tương tự giống với tính thông số của của biến tuổi với dữ liệu được đã sắp xếp.
Ta có tập dữ liệu sau sắp xếp của biến % mỡ là:

$$7.8,\ 9.5,\ 17.8,\ 25.9,\ 26.5,\ 27.2,\ 27.4,\ 28.8,\ 30.2,$$
$$31.2,\ 31.4,\ 32.9,\ 33.4,\ 34.1,\ 34.6,\ 35.7,\ 41.2,\ 42.5.$$

Nửa dưới:

$$7.8, 9.5, 17.8, 25.9, 26.5, 27.2, 27.4, 28.8, 30.2.$$

Có giá trị trung tâm là:

$$Q_1 = 26.5$$

Nửa trên:

$$31.2, 31.4, 32.9, 33.4, 34.1, 34.6, 35.7, 41.2, 42.5.$$

Có giá trị trung tâm là:

$$Q_3 = 34.1$$

Vậy khoảng tứ phân vị, tứ phân vị thứ nhất và thứ ba lần lượt là:

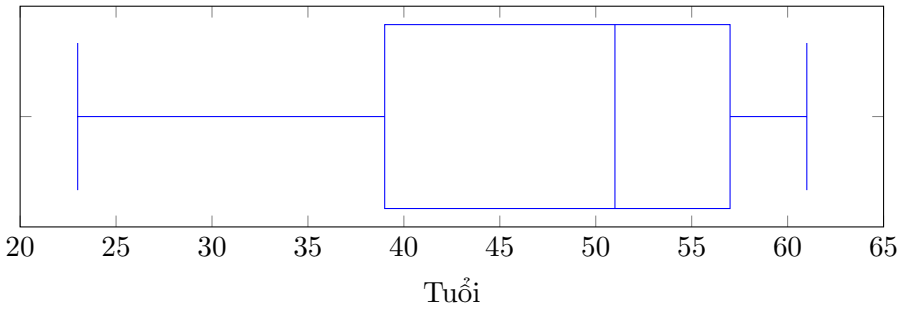
$$IQR = Q_3 - Q_1 = 34.1 - 26.5 = 7.6.$$

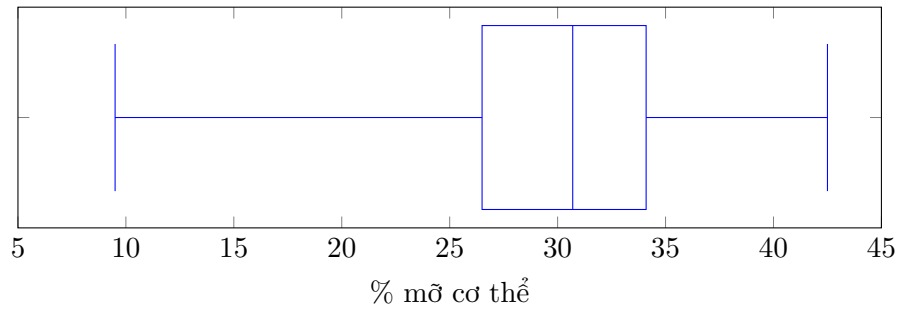
$$Q_1 - 1.5IQR = 26.5 - 1.5(7.6) = 15.1.$$

$$Q_3 + 1.5IQR = 57 + 1.5(18) = 45.5.$$

Vì 7.8 là outliner. nên whisker dưới sẽ bắt đầu lấy từ 9.5
Vậy, ta có tóm tắt 5 số của biến % mỡ lần lượt là: $\boxed{7.8,\ 26.5,\ 30.7,\ 34.1,\ 42.5}$

Boxplot của hai biến

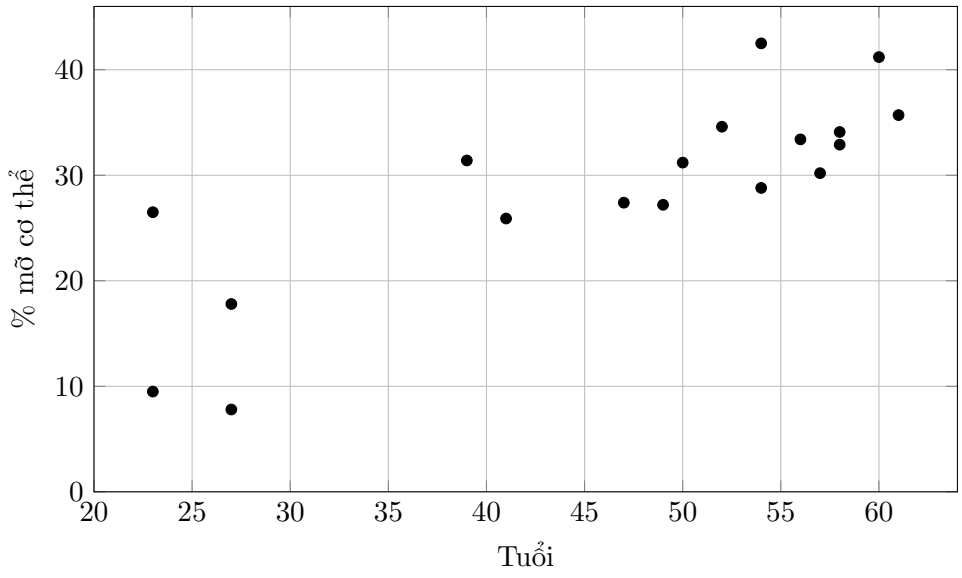




c. **Vẽ biểu đồ phân tán (Scatter plot)**
Dựa vào dữ liệu của từng độ tuổi và % mỡ, ta được các điểm dữ liệu như sau:

$$(23, 9.5), (23, 26.5), (27, 7.8), (27, 17.8),$$
$$(39, 31.4), (41, 25.9), (47, 27.4), (49, 27.2),$$
$$(50, 31.2), (52, 34.6), (54, 42.5), (54, 28.8),$$
$$(56, 33.4), (57, 30.2), (58, 34.1), (58, 32.9),$$
$$(60, 41.2), (61, 35.7).$$

Vậy, ta có biểu đồ phân tán như sau:



d. **Hệ số tương quan Pearson và Spearman**

Hệ số tương quan Pearson

Ta có công thức tính hệ số Pearson:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}.$$

Với:

$$\bar{x} = 46.40, \quad \bar{y} = 28.78.$$

Sau khi tính toán trên 18 cặp dữ liệu, ta thu được: $\boxed{r_{\text{Pearson}} \approx 0.8176}$.

Hệ số tương quan Spearman

Hệ số Spearman được tính bằng cách thay các giá trị ban đầu bằng thứ hạng (rank), sau đó tính tương quan Pearson trên các thứ hạng đó. Do dữ liệu có một số giá trị trùng nhau nên các giá trị trùng được gán thứ hạng trung bình.
Sau khi xếp hạng 18 quan sát và tính hệ số tương quan giữa hai dãy thứ hạng, ta thu được: $\boxed{\rho_{\text{Spearman}} \approx 0.8066}$.

Tóm tắt đáp án Bài 2

	Tuổi	% mỡ
Trung bình	46.40	28.78
Trung vị	51.00	30.70
Phương sai	157.67	84.55
Độ lệch chuẩn	12.56	9.20
Q_1	39	26.5
Q_3	57	34.1

Tóm tắt 5 số:

	Min	Q_1	Median	Q_3	Max
Tuổi	23	39	51	57	61
% mỡ	7.8	26.5	30.7	34.1	42.5

Hệ số tương quan Pearson và Spearman:

$$\boxed{r_{\text{Pearson}} \approx 0.8176, \qquad \rho_{\text{Spearman}} \approx 0.8066.}$$

Bài 3

Gọi D là số lần *ra sân*, số *bàn thắng* và số *kiến tạo* của Cristiano Ronaldo tại Champions League từ mùa giải 03/04 đến 21/22:

Mùa giải	**CLB**	**Ra sân**	**Bàn thắng**	**Kiến tạo**
03/04	Man United	5	0	1
04/05	Man United	7	0	2
05/06	Man United	6	0	0
06/07	Man United	11	3	5
07/08	Man United	11	8	1
08/09	Man United	12	4	3
09/10	Real Madrid	6	7	1
10/11	Real Madrid	12	6	4
11/12	Real Madrid	10	10	3
12/13	Real Madrid	12	12	1
13/14	Real Madrid	11	17	5
14/15	Real Madrid	12	10	4
15/16	Real Madrid	12	16	4
16/17	Real Madrid	13	12	6
17/18	Real Madrid	13	15	3
18/19	Juventus	9	6	2
19/20	Juventus	8	4	1
20/21	Juventus	6	4	2
21/22	Man United	7	6	0

a. Tính giá trị trung bình, trung vị, mốt, phương sai và độ lệch chuẩn của ba thuộc tính: *ra sân*, *bàn thắng* và *kiến tạo*.

b. Tìm tứ phân vị thứ nhất (Q_1) và tứ phân vị thứ ba (Q_3) của ba thuộc tính *ra sân*, *bàn thắng* và *kiến tạo*.

c. Vẽ các biểu đồ hộp (boxplot) của ba thuộc tính *ra sân*, *bàn thắng* và *kiến tạo*.

d. Vẽ các biểu đồ phân tán (scatter plot) của :

- *ra sân* và *bàn thắng*;
- *ra sân* và *kiến tạo*;
- *bàn thắng* và *kiến tạo*.

e. Tính ma trận hiệp phương sai (covariance matrix) của ba thuộc tính *ra sân*, *bàn thắng* và *kiến tạo*.

Bài giải

Gọi:

$$X = \text{số lần ra sân}, \qquad Y = \text{số bàn thắng}, \qquad Z = \text{số kiến tạo}.$$

Có tổng cộng $n = 19$ mùa giải. Từ bảng dữ liệu, ta thu được ba dãy số:

$$X = (5, 7, 6, 11, 11, 12, 6, 12, 10, 12, 11, 12, 12, 13, 13, 9, 8, 6, 7)$$

$$Y = (0, 0, 0, 3, 8, 4, 7, 6, 10, 12, 17, 10, 16, 12, 15, 6, 4, 4, 6)$$

$$Z = (1, 2, 0, 5, 1, 3, 1, 4, 3, 1, 5, 4, 4, 6, 3, 2, 1, 2, 0)$$

a. **Giá trị trung bình, trung vị, mốt, phương sai và độ lệch chuẩn**

Giá trị trung bình

Giá trị trung bình của từng biến Với $n = 19$:

$$\sum X_i = 183 \implies \bar{X} = \frac{183}{19} \approx 9.631$$

$$\sum Y_i = 140 \implies \bar{Y} = \frac{140}{19} \approx 7.368$$

$$\sum Z_i = 48 \implies \bar{Z} = \frac{48}{19} \approx 2.526$$

Trung vị

Vì $n = 19$ nên trung vị nằm ở vị trí thứ $\frac{19+1}{2} = 10$ sau khi sắp xếp tăng dần:

- $X_{\text{sorted}} = (5, 6, 6, 6, 7, 7, 8, 9, 10, \mathbf{11}, 11, 11, 12, 12, 12, 12, 12, 13, 13) \implies \text{Median}(X) = 11$
- $Y_{\text{sorted}} = (0, 0, 0, 3, 4, 4, 4, 6, 6, \mathbf{6}, 7, 8, 10, 10, 12, 12, 15, 16, 17) \implies \text{Median}(Y) = 6$
- $Z_{\text{sorted}} = (0, 0, 1, 1, 1, 1, 1, 2, 2, \mathbf{2}, 3, 3, 4, 4, 4, 5, 5, 5, 6) \implies \text{Median}(Z) = 2$

Mốt (Mode)

- $\text{Mode}(X) = 12$ (xuất hiện 5 lần).
- $\text{Mode}(Y) = \{4, 6\}$ (dữ liệu hai mốt, mỗi giá trị xuất hiện 3 lần).
- $\text{Mode}(Z) = 1$ (xuất hiện 5 lần).

Phương sai và độ lệch chuẩn mẫu ($n - 1 = 18$)

Áp dụng công thức phương sai mẫu $s^2 = \frac{1}{n-1}\sum(X_i - \bar{X})^2$:

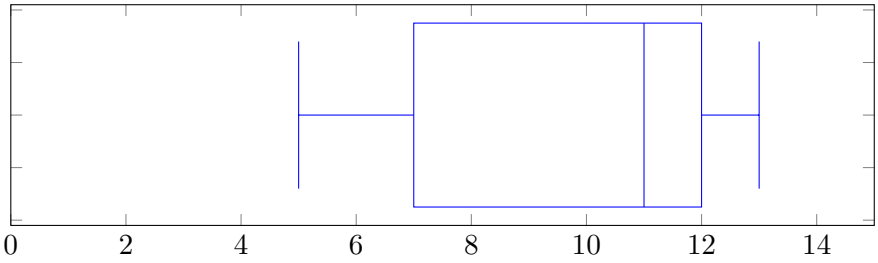
- Với X: $s_X^2 \approx 7.467 \implies s_X \approx 2.700$
- Với Y: $s_Y^2 \approx 28.023 \implies s_Y \approx 5.294$
- Với Z: $s_Z^2 \approx 3.263 \implies s_Z \approx 1.806$

b. **Tứ phân vị thứ nhất và thứ ba**
Loại bỏ trung vị (vị trí 10), chia dữ liệu thành 2 nửa (mỗi nửa 9 phần tử). Tứ phân vị Q_1, Q_3 là trung vị của nửa dưới và nửa trên:

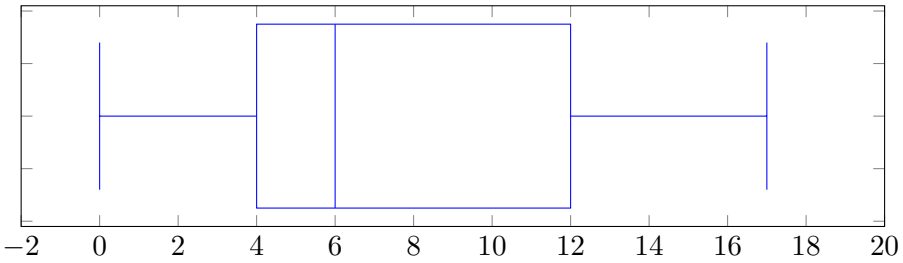
- Với X: $Q_1(X) = 7, \quad Q_3(X) = 12 \implies IQR(X) = 5$
- Với Y: $Q_1(Y) = 4, \quad Q_3(Y) = 12 \implies IQR(Y) = 8$
- Với Z: $Q_1(Z) = 1, \quad Q_3(Z) = 4 \implies IQR(Z) = 3$

c. **Biểu đồ hộp (Boxplot)**

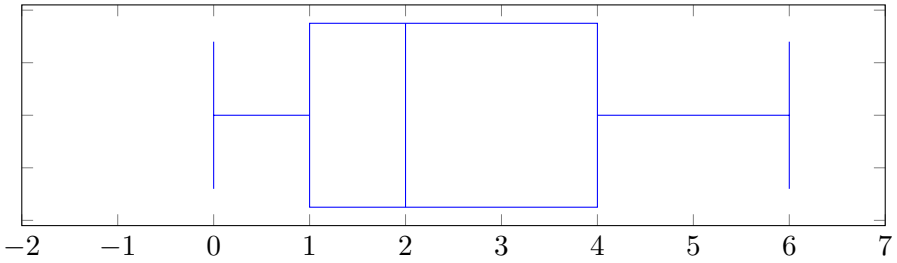
- X: $[5, 7, 11, 12, 13]$
- Y: $[0, 4, 6, 12, 17]$
- Z: $[0, 1, 2, 4, 6]$



Số lần ra sân của Cristiano Ronaldo

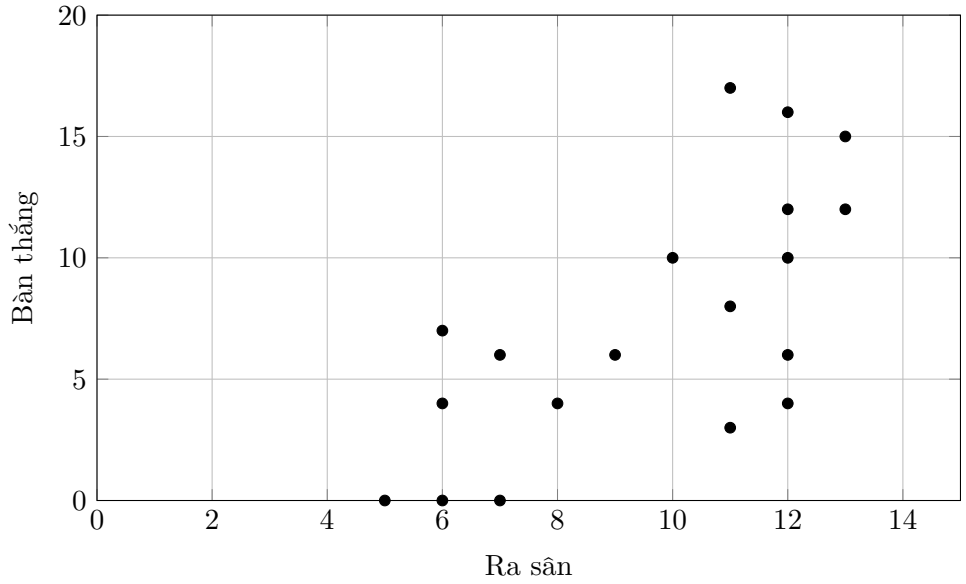


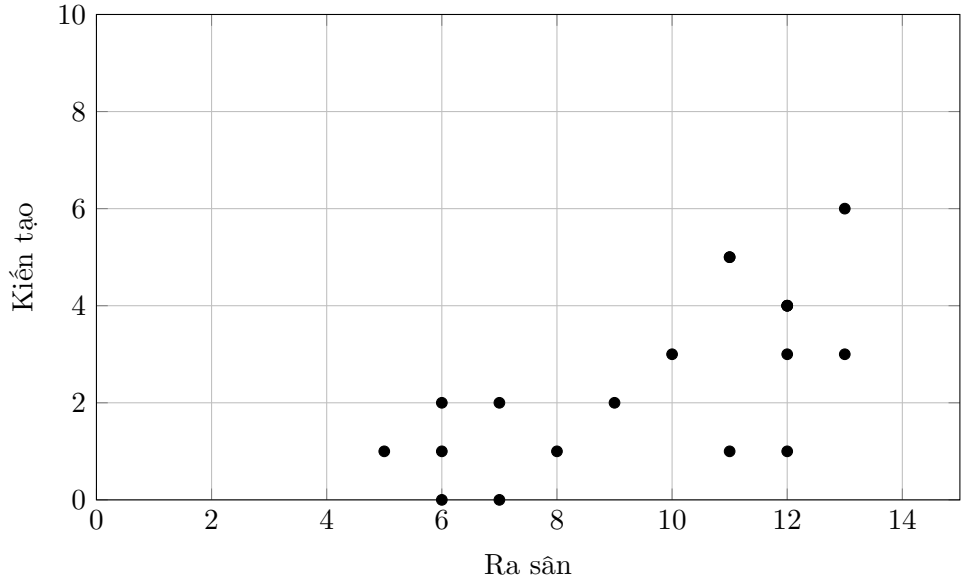
Số bàn thắng của Cristiano Ronaldo

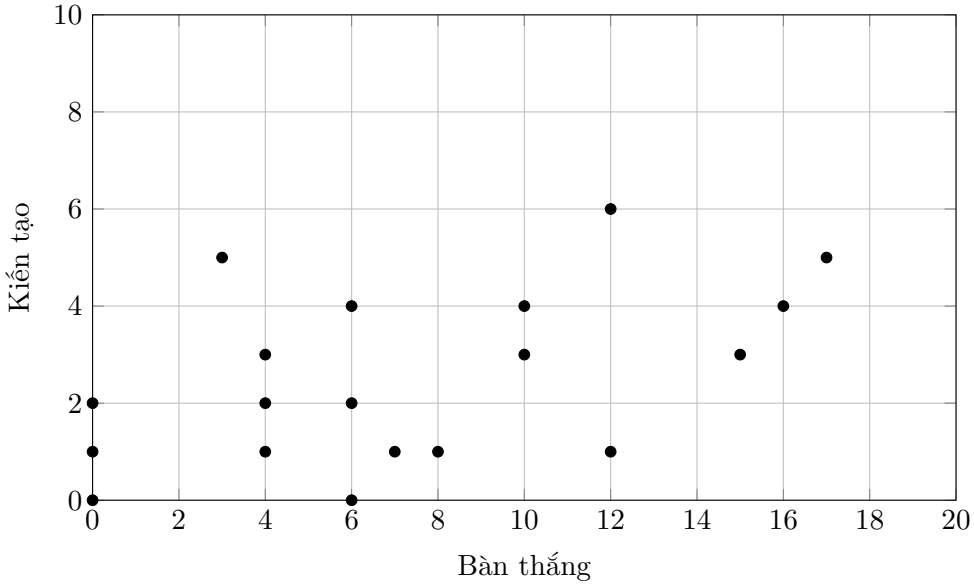


Số kiến tạo của Cristiano Ronaldo

d. **Biểu đồ phân tán (scatter plot)**







e. **Ma trận hiệp phương sai mẫu**

Với 19 mùa giải, ta có:

$$n = 19$$

Gọi:

$$X_1 = \text{ra sân}, \qquad X_2 = \text{bàn thắng}, \qquad X_3 = \text{kiến tạo}.$$

Giá trị trung bình của ba thuộc tính lần lượt là:

$$\bar{X}_1 = \frac{183}{19} \approx 9.6316,$$
$$\bar{X}_2 = \frac{140}{19} \approx 7.3684,$$
$$\bar{X}_3 = \frac{48}{19} \approx 2.5263.$$

Vì xem 19 mùa giải là một mẫu dữ liệu, ta sử dụng công thức hiệp phương sai mẫu:

$$\text{Cov}(X_i, X_j) = \frac{1}{n-1} \sum_{k=1}^{n} (x_{ki} - \bar{X}_i)(x_{kj} - \bar{X}_j).$$

Do đó, ma trận hiệp phương sai có dạng:

$$\mathbf{S} = \begin{pmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \text{Cov}(X_1, X_3) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \text{Cov}(X_2, X_3) \\ \text{Cov}(X_3, X_1) & \text{Cov}(X_3, X_2) & \text{Cov}(X_3, X_3) \end{pmatrix}.$$

Sau khi tính toán, ta thu được:

$$\boxed{\mathbf{S} = \begin{pmatrix} 7.4678 & 10.0322 & 3.3713 \\ 10.0322 & 28.0234 & 4.6842 \\ 3.3713 & 4.6842 & 3.1520 \end{pmatrix}}$$

Trong đó:

- $S_{11} = 7.4678$: phương sai của số lần ra sân.
- $S_{22} = 28.0234$: phương sai của số bàn thắng.
- $S_{33} = 3.1520$: phương sai của số kiến tạo.
- $S_{12} = 10.0322 > 0$: số lần ra sân và số bàn thắng có xu hướng đồng biến.
- $S_{13} = 3.3713 > 0$: số lần ra sân và số kiến tạo có xu hướng đồng biến.
- $S_{23} = 4.6842 > 0$: số bàn thắng và số kiến tạo có xu hướng đồng biến.

Tóm tắt đáp án Bài 3

Thuộc tính	**Mean**	**Median**	**Mode**	**Variance**	**Std. Dev.**
Ra sân	9.631	11	12	7.287	2.700
Bàn thắng	7.368	6	4, 6	28.023	5.294
Kiến tạo	2.526	2	1	3.263	1.806

Thuộc tính	Q_1	Q_3	IQR
Ra sân	7	12	5
Bàn thắng	4	12	8
Kiến tạo	1	4	3

$$\boxed{\mathbf{S} = \begin{pmatrix} 7.4678 & 10.0322 & 3.3713 \\ 10.0322 & 28.0234 & 4.6842 \\ 3.3713 & 4.6842 & 3.1520 \end{pmatrix}}$$

Bài 4

Có 800 sinh viên thuộc ba ngành (*Toán học*, *Lịch sử* và *Khoa học máy tính*) được hỏi liệu họ có thích chơi trò chơi máy tính hay không. Dữ liệu khảo sát được tổng hợp trong bảng chéo sau :

	Thích chơi game	Không thích chơi game	Tổng
Toán học	130	100	230
Lịch sử	35	165	200
Khoa học máy tính	280	90	370
Tổng	445	355	800

a. Tính tần số kỳ vọng (expected frequency) của từng ô trong bảng trên.

b. Sử dụng kiểm định chi-bình phương Pearson (Pearson's chi-square test) để xác định xem có mối liên hệ giữa ngành học và việc có thích chơi trò chơi máy tính hay không.

Bài giải

a. **Tính tần số kỳ vọng**
Tần số kỳ vọng của ô thuộc hàng i và cột j được tính theo công thức:

$$\boxed{E_{ij} = \frac{(\text{Tổng hàng } i)(\text{Tổng cột } j)}{\text{Tổng toàn bảng}}}$$

Với tổng số sinh viên:

$$N = 800.$$

Đối với từng ô:

$$E_{11} = \frac{230 \times 445}{800} = 127.9375$$

$$E_{12} = \frac{230 \times 355}{800} = 102.0625$$

$$E_{21} = \frac{200 \times 445}{800} = 111.25$$

$$E_{22} = \frac{200 \times 355}{800} = 88.75$$

$$E_{31} = \frac{370 \times 445}{800} = 205.6875$$

$$E_{32} = \frac{370 \times 355}{800} = 164.3125$$

Do đó, bảng tần số kỳ vọng là:

	Thích chơi game	Không thích chơi game	Tổng
Toán học	127.9375	102.0625	230
Lịch sử	111.2500	88.7500	200
Khoa học máy tính	205.6875	164.3125	370
Tổng	445	355	800

Các tần số kỳ vọng đều lớn hơn 5, do đó điều kiện thông thường để áp dụng kiểm định Chi-bình phương Pearson được đáp ứng.

b. **Kiểm định Chi-bình phương Pearson**

Đặt giả thuyết

Ta xét hai giả thuyết:

$$H_0 : \text{Ngành học và sở thích chơi game độc lập.}$$

$$H_1 : \text{Ngành học và sở thích chơi game có mối liên hệ.}$$

Chọn mức ý nghĩa:

$$\alpha = 0.05.$$

Tính thống kê kiểm định

Thống kê Chi-bình phương Pearson được tính theo công thức:

$$\boxed{\chi^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}}$$

Trong đó:

- O_{ij} là tần số quan sát được;
- E_{ij} là tần số kỳ vọng;
- r là số hàng;
- c là số cột.

Thay các giá trị quan sát và kỳ vọng vào công thức:

$$\begin{aligned}\chi^2 = &\frac{(130 - 127.9375)^2}{127.9375} + \frac{(100 - 102.0625)^2}{102.0625} \\ &+ \frac{(35 - 111.25)^2}{111.25} + \frac{(165 - 88.75)^2}{88.75} \\ &+ \frac{(280 - 205.6875)^2}{205.6875} + \frac{(90 - 164.3125)^2}{164.3125}.\end{aligned}$$

Suy ra:

$$\boxed{\chi^2 \approx 97.78}$$

Tính bậc tự do

Bảng có $r = 3$ hàng và $c = 2$ cột, do đó số bậc tự do là:

$$df = (r-1)(c-1)$$

$$df = (3-1)(2-1) = 2.$$

Vậy:

$$\boxed{df = 2}$$

So sánh với giá trị tới hạn

Với:

$$\alpha = 0.05, \qquad df = 2,$$

giá trị tới hạn của phân phối Chi-bình phương là:

$$\chi^2_{0.05,2} \approx 5.991.$$

Ta có:

$$\chi^2_{\text{tính toán}} = 97.78 > 5.991 = \chi^2_{\text{tới hạn}}.$$

Do đó, bác bỏ giả thuyết H_0.

Kết luận

Với mức ý nghĩa 5%, có đủ bằng chứng thống kê để kết luận rằng:

Ngành học và việc thích chơi trò chơi máy tính có mối liên hệ.

Nói cách khác, trong mẫu 800 sinh viên được khảo sát, tỷ lệ sinh viên thích chơi trò chơi máy tính có sự khác biệt giữa các ngành học.

Kết quả kiểm định chỉ cho thấy sự tồn tại của mối liên hệ giữa hai biến, không thể kết luận rằng ngành học là nguyên nhân gây ra sở thích chơi game.

Tóm tắt đáp án Bài 4

a) Tần số kỳ vọng

Ngành học	Thích chơi game	Không thích chơi game
Toán học	127.9375	102.0625
Lịch sử	111.2500	88.7500
Khoa học máy tính	205.6875	164.3125

Các tần số kỳ vọng đều lớn hơn 5, do đó điều kiện áp dụng kiểm định Chi-bình phương Pearson được đáp ứng.

b) Kiểm định Chi-bình phương Pearson

$$H_0: \text{ Ngành học và sở thích chơi game độc lập.}$$

$$H_1: \text{ Ngành học và sở thích chơi game có mối liên hệ.}$$

Với mức ý nghĩa:

$$\alpha = 0.05$$

Thống kê kiểm định:

$$\boxed{\chi^2 \approx 97.78}$$

Bậc tự do:

$$df = (3-1)(2-1) = 2$$

Giá trị tới hạn:

$$\chi^2_{0.05,2} \approx 5.991$$

Do:

$$97.78 > 5.991$$

nên bác bỏ H_0.

$$\boxed{\text{Ngành học và việc thích chơi trò chơi máy tính có mối liên hệ.}}$$

Kết quả chỉ cho thấy có sự liên hệ giữa hai biến, không thể kết luận ngành học là nguyên nhân gây ra sở thích chơi game.